

Analyse Prédicative et Classification avec Python : Étude Comparée de Modèles

AYMEN RGUIEG et SABRAOUI ADNANE

12/12/2024

Contents

1	Introduction	1
1.1	Contexte et problématique	1
1.2	Objectifs du projet et choix des algorithmes.	1
2	Exploration et Préparation des Données	2
2.1	Analyse Descriptive	2
2.2	Prétraitement des Données	2
3	Méthodologie	3
3.1	Présentation des Modèles	3
3.2	Optimisation des Hyperparamètres	3
4	Résultats et Analyse	3
4.1	Comparaison des performances entre Random Forest et Gradient Boosting	4
4.2	Importance des caractéristiques	4
5	Conclusion	5

1 Introduction

1.1 Contexte et problématique

Le vin est un produit complexe dont la qualité dépend de caractéristiques chimiques comme l'acidité, le pH, la teneur en alcool et en sucres résiduels. Traditionnellement évaluée par des dégustations humaines, cette qualité reste subjective et difficile à reproduire. L'analyse prédictive, basée sur des modèles d'apprentissage automatique, permet de prédire la qualité du vin de manière objective en exploitant ces données quantitatives, offrant ainsi une solution fiable pour améliorer les procédés de vinification.

1.2 Objectifs du projet et choix des algorithmes.

L'objectif est de prédire la qualité du vin et déterminer s'il peut être considéré comme bon ou mauvais.

Dans ce projet, nous avons utilisé deux modèles d'apprentissage automatique : Random Forest et XGBoost, chacun offrant des avantages spécifiques. Random Forest, basé sur une combinaison d'arbres de décision, est particulièrement efficace pour gérer des données bruitées et limiter le surapprentissage grâce à sa capacité à généraliser les tendances des données. En

parallèle, XGBoost, un algorithme de boosting optimisé, excelle dans la capture des relations complexes entre les variables grâce à son processus itératif d'amélioration des erreurs. Le choix de ces deux modèles nous permet de comparer leur performance pour prédire la qualité du vin et d'identifier la solution la plus adaptée aux caractéristiques des données étudiées.

2 Exploration et Préparation des Données

2.1 Analyse Descriptive




Figure 1: Analyse descriptive des données : structure, distribution et corrélation.

L'analyse descriptive des données est une étape essentielle pour comprendre la structure et les relations entre les variables. Le jeu de données comporte 13 colonnes avec 1143 observations, incluant des variables chimiques telles que l'acidité fixe, l'acidité volatile, le pH, et la teneur en alcool, ainsi qu'une variable cible : la qualité.

La distribution de la qualité révèle que la majorité des vins obtiennent des notes comprises entre 5 et 6, ce qui souligne un léger déséquilibre dans les données. Cela pourrait influencer les performances des modèles prédictifs, car les classes moyennes dominent.

La matrice de corrélation permet d'identifier les relations entre les variables. On observe une corrélation positive notable entre la qualité et la teneur en alcool (0.48), indiquant que des niveaux d'alcool plus élevés sont généralement associés à une meilleure qualité. À l'inverse, l'acidité volatile présente une corrélation négative significative (-0.41), ce qui suggère que des niveaux élevés d'acidité volatile peuvent impacter négativement la qualité du vin.

Ces résultats orientent l'analyse vers des caractéristiques clés qui influencent la qualité du vin, offrant ainsi une base solide pour la modélisation prédictive.


2.2 Prétraitement des Données

L'étape de prétraitement des données a révélé que le jeu de données est parfaitement structuré et exempt de problèmes courants. En effet, aucune valeur manquante n'a été détectée parmi les 1143 observations et 13 colonnes, garantissant une complétude totale des données. De plus, l'ensemble des variables est de nature quantitative (type float64 et int64), ce qui simplifie considérablement l'analyse et évite toute nécessité d'encodage de variables catégorielles. Aucune valeur aberrante évidente n'a été identifiée dans les caractéristiques numériques, assurant ainsi la qualité et la fiabilité des données pour les étapes d'exploration et de modélisation.

3 Méthodologie

3.1 Présentation des Modèles

Random Forest



Le modèle **Random Forest** est un ensemble d'arbres de décision indépendants. Chaque arbre est entraîné sur un sous-échantillon aléatoire des données, ce qui permet de réduire le surapprentissage (*overfitting*). La prédiction finale se fait par un vote majoritaire pour la classification ou par la moyenne pour la régression.

2

3.2 Optimisation des Hyperparamètres

GridSearchCV est une méthode d'optimisation qui permet de trouver les meilleurs hyperparamètres d'un modèle en testant systématiquement toutes les combinaisons possibles sur une grille prédéfinie. Chaque combinaison est évaluée via une validation croisée pour garantir des performances optimales. Par exemple, pour Random Forest ou Gradient Boosting, GridSearchCV ajuste des paramètres clés comme la profondeur des arbres ou le taux d'apprentissage, assurant ainsi un modèle plus précis et mieux adapté aux données.

4 Résultats et Analyse

Diviser le jeu de données en entraînement et test est crucial pour évaluer la capacité du modèle à généraliser. L'ensemble d'entraînement sert à ajuster le modèle, tandis que l'ensemble de test mesure ses performances sur des données non vues, réduisant ainsi le risque de surapprentissage. Une répartition typique de 70%-30% assure un bon équilibre entre apprentissage et évaluation.

```
# Binarisation de la variable cible
data['quality_binary'] = (data['quality'] >= 6).astype(int)


# Caractéristiques (toutes sauf 'quality', 'quality_binary' et 'Id')
features = data.drop(columns=['quality', 'quality_binary', 'Id'])

# Variable cible
target = data['quality_binary']

# Division en ensemble d'entraînement et de test
X_train, X_test, y_train, y_test = train_test_split(features, target, test_size=0.3, random_state=42)
```

Figure 2: Division de Data-Set

Gradient Boosting



Le modèle **Gradient Boosting** construit des arbres de décision séquentiels où chaque arbre corrige les erreurs des précédents. Il utilise un mécanisme de *boosting* qui ajuste les pondérations des données pour se concentrer sur les erreurs, améliorant ainsi la précision globale. Ce modèle est efficace pour capturer des relations complexes entre les variables.

4.1 Comparaison des performances entre Random Forest et Gradient Boosting




Figure 3: Comparaison des performances entre Random Forest et Gradient Boosting.

Modèle Random Forest :

- **Exactitude (accuracy) :** 77%.
- **Précision :** 0.72 (classe 0), 0.82 (classe 1).
- **Rappel :** 0.80 (classe 0), 0.75 (classe 1).
- **F1-score :** 0.76 (classe 0), 0.79 (classe 1).

Le modèle Random Forest présente un bon équilibre, notamment grâce à son rappel élevé pour la classe 0, ce qui montre une bonne capacité de détection.

Modèle Gradient Boosting :


- **Exactitude (accuracy) :** 76%.
- **Précision et rappel :** Les valeurs sont proches mais légèrement inférieures à celles de Random Forest.
- Le modèle Gradient Boosting est plus sensible aux déséquilibres des classes.

Bien que performant, il nécessite un réglage plus fin pour rivaliser avec la stabilité de Random Forest.

Conclusion : Random Forest offre des performances globalement plus équilibrées, tandis que Gradient Boosting reste compétitif mais requiert une optimisation supplémentaire pour des résultats optimaux.

4.2 Importance des caractéristiques

L'analyse de l'importance des caractéristiques révèle que les variables Feature 11, Feature 2 et Feature 10 sont celles qui contribuent le plus aux prédictions du modèle Gradient Boosting, avec une importance nettement plus élevée par rapport aux autres. Ces caractéristiques jouent un rôle clé dans la prise de décision du modèle, tandis que les variables comme Feature 3, Feature 4 et Feature 9 ont une influence beaucoup plus faible. Cette information permet d'optimiser l'analyse en se concentrant sur les variables les plus significatives, ce qui peut simplifier le modèle tout en conservant de bonnes performances.



(a) Importance des caractéristiques (b) Code Python utilisé pour l’affichage

Figure 4: Analyse de l’importance des caractéristiques avec Gradient Boosting.

5 Conclusion

Cette étude a permis de comparer les performances des modèles Random Forest et Gradient Boosting pour la prédiction et la classification de la qualité du vin en utilisant des caractéristiques chimiques. Les résultats montrent que Random Forest offre une meilleure stabilité globale, avec un équilibre satisfaisant entre précision et rappel, notamment pour la classe dominante. En revanche, Gradient Boosting, bien que légèrement en retrait, reste un modèle performant qui peut être optimisé davantage pour rivaliser avec Random Forest.

L’analyse de l’importance des caractéristiques a mis en évidence que certaines variables, telles que Feature 11, Feature 2 et Feature 10, contribuent de manière significative aux prédictions. Cela ouvre des perspectives pour simplifier le modèle en se concentrant sur les variables les plus pertinentes, tout en maintenant des performances élevées.

En conclusion, cette comparaison met en avant l’efficacité des modèles d’ensemble dans un cadre d’analyse prédictive, tout en soulignant l’importance de l’optimisation des hyperparamètres et de l’analyse des caractéristiques pour améliorer les performances des modèles.